

VADTree

Explainable Training-Free Video Anomaly Detection via Hierarchical Granularity-Aware Tree

사건의 시간 구조와 다중 해상도 이상 판단

Wenlong Li · Yifei Xu · Yuan Rao · Zhenhua Wang · Shuiguang Deng

EventVAD의 사건 단위에서, 긴 문맥과 짧은 행동의 결합으로

PRESENTER

박천웅

AFFILIATION

IRV_Lab

DATE

2026. 10. 02.

TIME LIMIT


20 min

01 이전 질문과 새 문제 사건 단위 · 시간 길이 · 경계 정합 00:40-03:25	02 사건 트리와 점수 융합 경계 → 두 해상도 → 문맥 보정 03:25-09:30
03 성능·비용·시각적 근거 AUC와 AP · 실행시간 · 정성 결과 09:30-16:30	04 한계와 연구적 연결 설명 신뢰성 · 기존 발표와의 차이 16:30-19:00

본편 22장 · 계획 19분 + 전환 여유 1분

상세 수식·추가 표는 부록 · 질의응답 별도

이전 세미나의 세 가지 질문



07.29 · EventVAD · 4장



08.12 · MemoVAD · 4장



09.11 · BEM · 11장

어느 구간을 볼 것인가

“MLLM의 시간 단위 불일치”
프레임·전체 영상·고정 클립의 한계

언제 큰 모델을 부를 것인가

“선택적 VLM 질의”
호출을 줄이고 확인한 의미를 재사용

어떤 근거로 점수를 바꿀까

“유사도 기반 재점수화”
배경 특징과 후보 검출 점수의 연결

오늘의 초점: 사건의 시간 길이를 구조화하고, 서로 다른 구간의 판단을 결합하는 방법

고정 길이와 사건 길이




Fig. 1 A-B · 동일 장면의 고정 창과 계층적 사건 구간

고정 창의 혼합

10초 창에 정상 행동과 다툼이 함께 들어가면, 설명과 점수가 섞일 수 있다.

두 시간 해상도

Coarse: 다툼의 전체 흐름
Fine: 언쟁·공격 같은 국소 행동

GT 9.0-14.6초: 논문이 표시한 Fighting 정답 구간

사건 길이별 구간 정합




Fig. 1 C · UCF-Crime 위 / XD-Violence 아래

그래프 읽기

가로축: 이상 사건 길이(초)
세로축: 정답과 샘플 구간의 최대 IoU
파랑: 트리 · 빨강: 10초 고정 창

직접 보여주는 것

길이가 다양한 사건에서, 트리가 높은 시간 겹침을 가진 후보 구간을 제공한다.

Fig. 1의 UCF mIoU 0.52는 Table 14의 중복 노드 포함 값과 일치. 최종 VADTree 구성의 mIoU는 0.47이다.

VADTree 전체 구조




Fig. 2 · 왼쪽: 구간 구조화 / 오른쪽: 설명 · 점수 · 보정

1. 사건 트리

GEBD 경계 → coarse / fine 구간

2. 구간별 판단

사전 지식 + VLM 설명 → LLM 점수

3. 두 단계 보정

동일 군집 이웃 → 부모·자식 융합

일반 사건 경계: 영상의 의미가 전환될 가능성이 높은 시점



아래 시간·신뢰도는 설명용 예시. 일반 사건 경계는 이상 사건의 정답 경계와 구별된다.

Coarse·Fine 군집과 중복 제거




Fig. 2 왼쪽 · 트리 → 두 군집 → 노드 정리

경계 신뢰도의 두 군집

K-means로 경계 점수를 둘로 나눈다.
명확한 경계 중심의 coarse와 더 세밀한 fine을 구성한다.

RemoveDup

각 군집의 경로에서 가장 세밀한 노드를 남기고 중복 조상을 제거한다.

Complete

더 나눌 수 없는 coarse 구간을 fine에 복사해 전체 영상의 빈 구간을 채운다.

두 군집 모두 영상 전체를 덮도록 구성한다. 노드 개수 2개를 뜻하지 않는다.

사전 지식과 구간별 이상 점수



Training-free: VAD용 파라미터 갱신 없이 추론. 부록 프롬프트에는 데이터셋별 이상 유형 목록이 주어진다.

유사한 사건의 점수 보정

같은 군집에서 의미가 비슷한 노드의 점수를 참조

$$\hat{a}_u = \sum_{v \in \text{Top-K}(u)} \text{softmax}(\text{sim}(u,v) / \tau) \cdot a_v$$

유사도와 이웃

ImageBind 특징의 코사인 유사도

같은 coarse 또는 fine 집합에서 top-K 선택

온도 τ 와 가중 평균

작은 τ : 가장 유사한 노드에 집중

큰 τ : 이웃의 비중이 평탄해짐

시간상 바로 옆 노드에 한정되지 않는다. 시각적으로 비슷한 정상·이상 장면이 섞이면 점수가 희석될 수 있다.

부모·자식 점수의 융합

자식 점수들의 분산으로 긴 문맥과 짧은 단서의 비중을 조절

$$\text{최종 점수} = \frac{1}{2}(1 - \beta\hat{w}) \cdot \text{부모 점수} + \frac{1}{2}(1 + \beta\hat{w}) \cdot \text{자식 점수}$$

$$\hat{w} = 0 \cdot \beta = 0.4$$

부모 50% + 자식 50%

자식 판단이 일치하면 균등 결합

$$\hat{w} = 1 \cdot \beta = 0.4$$

부모 30% + 자식 70%

자식 판단이 다르면 짧은 단서 강조

$\hat{w}$: 자식들의 보정 점수 분산을 정규화한 값. $\beta=0.4$ 는 UCF-Crime 부록 선택값. 예시 계산은 Eq. (10) 기준.

실험 조건과 평가 지표

항목	논문 설정
모델	EfficientGEBD · ImageBind · 7B VLM · DeepSeek-R1-Distill-Qwen-14B
입력·추론	VLM 최대 64프레임 · LLM Think 모드 기본 사용
UCF-Crime / XD-Violence	프레임 ROC-AUC / 프레임 ROC-AUC와 AP
MSAD	전체 지표와 이상 특화 지표를 분리해서 확인

ROC-AUC

정상·이상 프레임의 점수 순위 구분

AP

Precision-Recall에 기반한 탐지 품질

본문은 LLaVA-Video-7B-Qwen2, Table 6은 LLaVA-NeXT-Video-7B로 표기. 정확한 체크포인트는 재현 시 대조 필요.

UCF·XD 주요 결과

Training-free 방법	UCF AUC (%)	XD AUC (%)	XD AP (%)
LAVAD	80.28	85.36	62.01
EventVAD	82.03	87.51	64.04
SUVAD	83.90	—	70.10
VADTree · 시각 입력	84.74	90.44	67.82
VADTree* · 음향 추가	—	90.55	68.85

EventVAD 대비

UCF AUC +2.71%p
XD AUC +2.93%p · AP +3.78%p

지표별 순위

XD AP: 67.82 < SUVAD 70.10
음향 추가 결과는 별도 행으로 구분

출처는 VADTree의 Tables 1-2. 기존 EventVAD 발표의 다른 베이스라인 수치와 섞지 않는다.

MSAD의 전체·이상 특화 평가

방법	AUC (%)	AUC _a (%)	AP (%)	AP _a (%)
GS-MoE · 약지도	87.72	69.54	68.26	76.68
π -VAD · 약지도	88.68	71.25	71.26	77.86
VADTree · training-free	89.32	67.85	71.41	75.49

전체 지표

표에 제시된 비교에서 AUC·AP가 가장 높음

이상 특화 지표

AUC_a·AP_a는 π -VAD가 더 높음
전체 우위의 범위를 구분

하첨자 a는 논문이 anomaly-specific으로 구분한 평가. 상세 계산 프로토콜은 본문에서 충분히 풀어 쓰지 않는다.

Table 5 · 누적 추가	UCF AUC (%)	직전 행 대비
HGTree Fine Cluster	71.57	—
+ 사전 지식	75.67	+4.10%p
+ 군집 내 보정	83.05	+7.38%p
+ 군집 간 융합	84.74	+1.69%p

가장 큰 단계 상승

누적 구성에서는 유사 이웃의 점수 보정 효과가 크다.

해석의 범위

추가 순서에 의존하는 차이
각 모듈의 독립적인 인과 효과와 구분

부록 Table 13: 완성 모델에서 refinement 제거 시 77.97, correlation 제거 시 83.05.

샘플 수와 실제 계산 비용

샘플 구간 수 · Table 14

구성	구간 수	AUC
10초 창 · stride 16f	69,634	82.87
VADTree	8,613	84.74

구간 수 87.6% 감소 · 약 8.1배 적음
비중첩 10초 창은 3,852개로 VADTree보다 적음

UCF 총 GPU 시간 · Table 16

구성	GPU·h	AUC
LAVAD	55.9	80.28
VADTree · Think	62.3	84.74
VADTree · no-Think	44.5	84.65
VADTree · t5gemma	41.5	84.00

MemoVAD 때의 질문: 무엇이 비용을 줄였는가?

이번에는 구간 수를 줄인다. 실제 비용은 VLM·LLM과 추론 모드까지 포함해서 봐야 한다.

2×RTX 3090 조건의 논문 보고. LAVAD 일부 단계 시간은 추정치. GPU·h는 프레임 지연시간이나 FPS가 아니다.

정성 결과의 읽는 법




Fig. 3 전체 · 위 UCF-Crime / 아래 XD-Violence

■ 청록 구간 = coarse ■ 분홍 구간 = fine ■ 파란 선 = 최종 점수 ■ 빨간 배경 = GT 이상 구간

가로축: 프레임/초 병기 / 세로축: 이상 점수 0-1. 텍스트는 모델이 생성한 설명이다.

UCF의 절도·정상 매장 사례




Fig. 3 위쪽 확대 · 왼쪽 Stealing036 / 오른쪽 정상 매장

왼쪽 · 절도 사례

빨간 GT 구간에서 점수가 높아지지만,
정답 시작·끝과 완전히 일치하지는 않는다.

오른쪽 · 정상 매장

일하는 사람과 물건을 든 행동을
일상 문맥으로 설명하며 낮은 점수를 유지한다.

XD의 폭행·시위 보도 사례




Fig. 3 아래쪽 확대 · 왼쪽 폭행 장면 / 오른쪽 시위·인터뷰 전환

왼쪽 · 행동 변화

정적인 대화에서 제압·저항으로 넘어갈 때
국소 행동 단서와 점수 상승이 대응한다.

오른쪽 · 장면 전환

충돌 장면과 인터뷰 구간의 점수가 달라진다.
긴 보도 맥락과 짧은 행동 판단을 함께 본다.

설명 신뢰성과 적용 한계

시각 단서의 누락

작은 불꽃·작은 객체처럼 VLM이 못 본 단서는 후단의 추론·점수 보정으로 복원하기 어렵다.

사전 지식의 편향

이상 유형 목록과 의심 단서가 설명을 유도한다. 생성 문장의 유창함과 관찰 근거의 정확성은 별도 검증이 필요하다.

온라인 처리 조건

전체 영상의 트리와 군집 이웃을 사용한다. 미래 프레임 없이 즉시 판단하는 스트리밍 성능은 별도 문제다.

지표·비용의 조건

AUC 개선과 AP 우위는 다르다.
기본 Think 설정은 GPU 시간이 더 크다.

기존 발표와의 연구적 연결

이전 발표의 질문	VADTree에서의 대응	직접 연결할 지점
EventVAD · 어느 구간?	일반 사건 경계 + coarse/fine 트리	단일 분할과 다중 시간 문맥 비교
MemoVAD · 언제 질의?	샘플 구간 수 축소 + 모델별 비용	호출 횟수와 총 지연을 따로 측정
BEM · 어떤 보정 근거?	이웃 점수 + 부모·자식 관계	어떤 점수가 왜 변했는지 추적

공통된 설계 관점

큰 모델의 판단에 들어갈 단위를 정하고, 문맥을 근거로 출력을 보정한다.

학습 설정·출력 과제가 서로 다르다. 이 표는 구조적 비교이며 공통 벤치마크 성능 비교가 아니다.

01

사건의 시간 구조

일반 경계로 트리를 만들고
긴 문맥과 짧은 행동을 함께 표현

02

판단의 상호 보정

의미 이웃의 점수를 참조하고
부모·자식 판단을 결합

03

조건부 성능·효율

높은 AUC와 적은 샘플 수
AP와 실제 비용은 별도 확인

발표의 핵심: 무엇을 하나의 사건으로 볼 것인가

본편 계획 종료 19:00 · 남은 1분은 전환 여유

질의응답용 부록 열기 →