

VADTree

Explainable Training-Free Video Anomaly Detection via Hierarchical Granularity-Aware Tree

사건 경계의 트리 구조와 두 단계 점수 보정

Wenlong Li · Yifei Xu · Yuan Rao · Zhenhua Wang · Shuiguang Deng

고정 길이의 한계에서 사건 트리와 다중 해상도 판단으로

PRESENTER

박천웅

AFFILIATION

IRV_Lab

DATE

2026. 10. 02.

TIME LIMIT

20 min

목차

01**문제와 선행연구**

고정 창 의 한계 · 사건 길이

02**트리 생성**

일반 경계 · 부모·자식 · 두 해상도

03**판단과 보정**


구간 설명 · 유사 이웃 · 부모·자식 융합

04**실험과 한계**

성능 · 구성요소 · 비용 · 사례

핵심 질문: 어디서 나누고, 어떤 구간을 판단하며, 무엇을 근거로 점수를 바꾸는가?

이전 세미나의 세 가지 질문



07.29 · EventVAD · 4장



08.12 · MemoVAD · 4장



09.11 · BEM · 11장

어느 구간을 볼 것인가

“MLLM의 시간 단위 불일치”
프레임·전체 영상·고정 클립의 한계

언제 큰 모델을 부를 것인가

“선택적 VLM 질의”
호출을 줄이고 확인한 의미를 재사용

어떤 근거로 점수를 바꿀까

“유사도 기반 재점수화”
배경 특징과 후보 검출 점수의 연결

오늘의 초점: 사건의 시간 길이를 구조화하고, 서로 다른 구간의 판단을 결합하는 방법

고정 창과 사건 길이




Fig. 1 A-B · 고정 창과 계층적 사건 구간 · 클릭하여 원문 확대

왼쪽 A · 10초 고정 창

다툼의 앞뒤 정상 장면이 섞이거나, 다툼 자체가 창 경계에서 잘린다.

오른쪽 B · coarse와 fine

9.0-14.6초의 전체 다툼과 그 안의 언쟁·공격을 서로 다른 길이로 표현한다.

빨간 GT는 9.0-14.6초 Fighting. 그림의 설명·점수는 모델 출력 사례이며 정확도 검증은 아니다.

사건 길이와 구간 정합




Fig. 1 C · 사건 길이와 최대 시간 IoU · 클릭하여 원문 확대

가로축 · 사건 지속 시간

짧은 사건부터 긴 사건까지. 세로축은 정답 사건과 가장 잘 겹치는 후보 구간의 시간 IoU.

곡선과 점의 의미

고정 10초 창은 자기 길이에서 유리하다. 트리는 여러 길이의 후보를 낸다.

수치의 범위

UCF의 Fig. 1 평균 0.52는 중복 노드 포함 구성. 최종 VADTree는 Table 14에서 0.47.

VADTree 전체 경로




Fig. 2 · 트리 생성에서 최종 점수까지 · 클릭하여 원문 확대

① 일반 경계 → 트리

② coarse·fine 노드 판단

③ 같은 집합 보정

④ 부모·자식 융합

경계 신뢰도

Eq. 1 · 지역 신호

$$C_{local}^{(k)} = [(t_1, c_1), (t_2, c_2), \dots, (t_{l_{raw}}, c_{l_{raw}})] = f_{GEBD} \left(V_{local}^{(k)} \right),$$

k번째 겹침 창 의 프레임마다 경계 신뢰도 c를 생성

Eq. 2 · 전역 연결

$$C = \text{Concat}_{k=1}^K \left(C_{local}^{(k)} \left[\left\lfloor \frac{1}{4} l_{raw} \right\rfloor : \left\lfloor \frac{3}{4} l_{raw} \right\rfloor \right] \right),$$
$$\hat{C} = \{(t, \hat{c}) \mid \text{LocalMax}(C, t)\},$$

각 창 의 l_raw 프레임 중 중앙 절반만 전역 시간에 연결

Eq. 3 · 후보

$$C(t) \geq C(t \pm 1).$$

전체 신호 C(t)의 국소 최대를 경계 후보로 선택

c는 경계 신뢰도(confidence)이고 a는 뒤에서 만들 이상 점수다. t는 초가 아닌 전역 프레임 인덱스다.

t_i = 전체 영상의 프레임 위치

C_{local}^(k) = 그 창 의 (t,c) 점수 목록


c_i = 그 위치의 경계 신뢰도, 0-1

l_{raw} = 입력 창 길이, 프레임 수

V_{local}^(k) = k번째 영상 입력 창

C / Ĉ = 전역 신호 / 봉우리 후보 집합

재귀 분할과 중단



시간은 절차 설명용 예시. 실제 분할은 이상 점수나 정답 라벨로 결정하지 않는다.

분할 기준

노드 N_i 의 프레임 구간에서 최대 경계 후보 $\hat{c}_{\max}$ 를 골라 자식 둘로 나눈다.

중단 기준

후보가 없거나 $\hat{c}_{\max} < \gamma_{\min} = 0.4$ 이면 그 노드의 분할을 멈춘다.

남는 구조

N_i 는 좌우 경계 신뢰도와 영상 구간 V_i 를 담는다. 부모도 남는다.

두 시간 해상도




Fig. 2 왼쪽 · coarse와 fine 노드 선택 · 클릭하여 원문 확대

경계 신뢰도의 두 무리

$\hat{C}_{coarse}$ / $\hat{C}_{fine}$ 은 경계 후보 신뢰도의 두 집합.
 S_{coarse} / S_{fine} 은 각 기준으로 선택한 노드 집합이다.
 고정 깊이가 아니다.

중복 제거와 보완

S' 는 중복 제거·빈 구간 보완 뒤 집합이다. RemoveDup은 세밀한 노드를 남기고 Complete는 fine의 빈 시간 구간을 채운다.

$$\begin{aligned}
 (\hat{C}_{coarse}, \hat{C}_{fine}) &= \text{K-Means}(\hat{C}, 2), \\
 S_{coarse} &= \left\{ \mathcal{N}_i \mid \min(\hat{c}_l^i, \hat{c}_r^i) \geq \min(\hat{C}_{coarse}) \right\}, \quad S_{fine} = \left\{ \mathcal{N}_i \mid \min(\hat{c}_l^i, \hat{c}_r^i) \leq \max(\hat{C}_{fine}) \right\}, \\
 S'_{coarse} &= \text{RemoveDup}(S_{coarse}), \quad S'_{fine} = \text{Complete}(\text{RemoveDup}(S_{fine})),
 \end{aligned}$$

$\hat{c}_l \cdot \hat{c}_r$ = 노드 양 끝의 경계 신뢰도

구간별 초기 판단




Fig. 2 오른쪽 · 노드 설명과 이상 점수 · 클릭하여 원문 확대

① 공유하는 사전 지식 B

$B = (b_scene, b_obj, b_act)$: 장면·객체·행동 사전 지식.

② 노드별 영상 설명 d

d_u^g : g 집합의 u번 노드에서 뽑은 프레임을 VLM이 설명한 문장.

③ 초기 이상 점수 a

a_u^g : 설명에 대해 LLM이 매긴 초기 이상 점수, $0 \cdot 0.1 \cdots 1$.

$$B = (b_{scene}, b_{obj}, b_{act}) = f_{LLM_{gen}}(P_b \circ P_c).$$

$$d_u^g = f_{VLM}(V_u^g, B \circ P_d).$$

$$a_u^g = f_{LLM}(d_u^g, P_s).$$

$g = \text{coarse/fine}$ · $u = \text{노드 번호}$ · $V_u^g = \text{추출 프레임}$ · $P_b/P_c/P_d/P_s = \text{생성/제약/설명/채점 지시문}$

군집 내 점수 보정

$$\hat{a}_u^g = \underbrace{\sum_{i=1}^K a_{\kappa_u^{(i)}}}_{\text{Initial scores}} \cdot \underbrace{\frac{\exp(\text{sim}(u, \kappa_u^{(i)})/\tau)}{\sum_j^K \exp(\text{sim}(u, \kappa_u^{(j)})/\tau)}}_{\text{Softmax weights}}$$

보정 점수 = 유사한 이웃들의 초기 점수 × 유사도 가중치

이웃의 범위

같은 coarse 집합 또는 같은 fine 집합 전체에서 시각 특징이 비슷한 top-K 노드를 찾는다.

식의 가중치

ImageBind 특징의 코사인 유사도를 softmax로 바꾼다. 시간상 옆 구간만 뜻하지 않는다.

의도와 위험

독립 점수의 흔들림을 줄이지만, 비슷한 정상 장면이 섞이면 실제 이상도 희석될 수 있다.

첫 보정은 같은 해상도 안에서 점수를 바꾼다. 아직 부모와 자식을 섞지 않는다.

u / g = 대상 노드 / coarse 또는 fine

sim / τ = 코사인 유사도 / 가중치 온도

$\kappa_u^{(i)}$ = u 와 닮은 i 번째 노드

$a / \hat{a}$ = 초기 점수 / 유사 이웃으로 보정한 점수

K = 사용할 유사 노드의 개수

부모·자식 점수 융합

$$w_i = \frac{1}{m} \sum_{j=1}^m (\hat{a}_{nij} - \mu_i)^2, \quad \text{where } \mu_i = \frac{1}{m} \sum_{j=1}^m \hat{a}_{nij}.$$

$$\bar{a}_{nij} = \frac{1}{2}(1 - \beta \hat{w}_i) \hat{a}_{ni} + \frac{1}{2}(1 + \beta \hat{w}_i) \hat{a}_{nij}.$$

Eq. 9 · 자식들 사이의 차이

한 부모에 속한 자식들의 보정 점수 분산을 계산한다.

Eq. 10 · 가중치 이동

정규화된 분산이 커질수록 긴 부모보다 짧은 자식 점수의 비중이 높아진다.

β = 0.4 계산

분산 0: 부모/자식 50/50
분산 1: 부모/자식 30/70

최종 점수는 각 fine 구간에 부여되고 해당 시간의 프레임 점수로 이어진다.

i / i_j = 부모 / 그 아래 j번째 자식
â = 첫 보정 뒤의 노드 점수

m / μ_i = 자식 수 / 자식 점수 평균
β = 부모·자식 비중 조절 계수

w_i / ŵ_i = 자식 점수 분산 / 정규화값
ā = 융합 후 fine 노드의 최종 점수

융합 계산 예시

긴 부모 구간의 보정 점수

0.3

맥락은 비교적 정상

짧은 자식 구간의 보정 점수

0.9

국소 행동은 높은 이상

$\beta = 0.4 \cdot$ 정규화 분산 $\hat{w} = 0.5$

부모 40% + 자식 60%

$0.4 \times 0.3 + 0.6 \times 0.9 = 0.66$

분산 0이면

같은 부모 아래 자식 판단이 일치하는 경우: $0.5 \times 0.3 + 0.5 \times 0.9 = 0.60$

분산 1이면

자식 판단이 크게 다른 경우: $0.3 \times 0.3 + 0.7 \times 0.9 = 0.72$

수치는 식의 작동을 설명하기 위한 가상 예시. 실제 영상·실험 결과가 아니다.

실험의 검증 질문

탐지 성능 UCF-Crime · XD-Violence · MSAD 프레임 ROC-AUC와 AP를 분리	구성요소 사전 지식 · 이웃 보정 · 부모·자식 융합 UCF 누적·제거 실험	비용과 설명 후보 구간 수 · GPU 시간 · 정성 사례 샘플 수와 총비용을 구별
성능표는 최종 시스템 비교, 구성요소 표는 방법 내부 변화, Fig. 3은 개별 사례다.		

UCF-Crime 비교

Blip2 [18]	Training-free	46.42
ZS CLIP [27]	Training-free	53.16
ZS ImageBind (Image) [12]	Training-free	53.65
ZS ImageBind (Video) [12]	Training-free	55.78
LLaVA-1.5 [20]	Training-free	72.84
Video-Llama2 [58]	Training-free	74.42
LAVAD [55]	Training-free	80.28
SUVAD [11]	Training-free	83.90
MCANet [9]	Training-free	82.47
EventVAD [30]	Training-free	82.03
VADTree(Ours)	Training-free	84.74

Table 1의 training-free 행 · 클릭하여 원문 확대

비교 범위

오른쪽 AUC 열린 프레임 ROC-AUC. 같은 회색 영역의 training-free 방법끼리 먼저 비교한다.

결과

EventVAD 82.03 → VADTree 84.74: +2.71%p.
SUVAD 83.90보다 +0.84%p.

해석 제한

위쪽 fine-tuning·verbalized learning 행까지 모두 이긴 결과가 아니다.

XD-Violence 비교

Explainable VAD Methods			
Holmes-VAD [59]	Fine-tuning	90.67	-
Holmes-VAU [60]	Fine-tuning	87.68	-
VERA [50]	Verbalized Learning	70.54	88.26
Blip2 [18]	Training-free	10.89	29.43
ZS CLIP [27]	Training-free	17.83	38.21
ZS ImageBind (Image) [12]	Training-free	27.25	58.81
ZS ImageBind (Video) [12]	Training-free	25.36	55.06
LLaVA-1.5 [20]	Training-free	50.26	79.62
Video-Llama2 [58]	Training-free	53.57	80.21
LAVAD [55]	Training-free	62.01	85.36
SUVAD [11]	Training-free	70.10	-
MCANet* [9]	Training-free	69.72	87.43
EventVAD [30]	Training-free	64.04	87.51
VADTree (Ours)	Training-free	67.82	90.44
VADTree* (Ours)	Training-free	68.85	90.55

Table 2 중 explainable 방법과 training-free 행 · 왼쪽 수치 AP, 오른쪽 AUC · 클릭하여 원문 확대

두 지표

원문 수치 열은 AP 다음 AUC. 높은 AUC가 높은 AP를 자동으로 뜻하지 않는다.

AUC

EventVAD 87.51 → VADTree 90.44: +2.93%p.

AP와 입력

VADTree 67.82 < SUVAD 70.10. 별표 VADTree*는 음향을 추가한 별도 구성.

MSAD의 결과 범위

Method	Supervision	AUC (%)	AUC _a (%)	AP (%)	AP _a (%)
RTFM [37]	Weakly Supervised	86.65	-	-	-
MGFN [4]	Weakly Supervised	84.96	-	-	-
TEVAD [3]	Weakly Supervised	86.82	-	-	-
UR-DMU [26]	Weakly Supervised	85.78	67.95	67.35	75.30
GS-MoE [7]	Weakly Supervised	87.72	69.54	68.26	76.68
π -VAD [26]	Weakly Supervised	88.68	71.25	71.26	77.86
VADTree (Ours)	Training-free	89.32	67.85	71.41	75.49

Table 3 · MSAD 전체 지표와 이상 특화 지표 · 클릭하여 원문 확대

전체 AUC·AP

VADTree 89.32 / 71.41: 이 표의 비교 행에서 가장 높다.

이상 특화 AUC_a·AP_a

π -VAD 71.25 / 77.86 > VADTree 67.85 / 75.49.

구성요소 기여

Module	AUC (%)	
HGTree Fine Cluster	71.57	
+ Prior-infused Node Scoring	75.67	71.57 → 75.67 사전 지식 추가: +4.10%p
+ Intra-cluster Node Refinement	83.05	75.67 → 83.05 같은 집합의 유사 이웃 보정: +7.38%p
+ Inter-cluster Node Correlation	84.74	83.05 → 84.74 부모·자식 융합: +1.69%p

Table 5 · 모듈을 순서대로 추가한 UCF AUC · 클릭하여 원문 확대

이 표는 누적 추가 순서의 변화다. 각 모듈을 따로 켜올 때의 독립 효과는 아니다.

구간 수와 정합

Method	TW Length	Stride	NoS↓	mIoU↑	mIF↑	AUC (%)
sliding TW	5s	5s	7558	0.41	122	82.06
sliding TW	10s	10s	3852	0.40	191	82.81
sliding TW	20s	20s	1994	0.33	265	81.33
sliding TW	10s	16f [55, 50]	69634	0.51	210	82.87
VADTree-Coarse	-	-	2248	0.37	369	82.81
VADTree-Fine	-	-	6365	0.40	233	83.05
VADTree	-	-	8613	0.47	343	84.74
VADTree + Redundant	-	-	12440	0.52	456	-

Table 14 · 샘플링별 구간 수, mIoU, mIF, AUC · 클릭하여 원문 확대

NoS · 생성 구간 수

츠츠한 10초 창 69,634
VADTree 8,613

mIoU · 시간 정합

츠츠한 창 0.51
최종 트리 0.47

AUC · 탐지 결과

츠츠한 창 82.87
최종 트리 84.74

전체 계산 비용

Methods	HGTree Construction	Video/Text Encoding	VLM Caption	LLM Summary	LLM Scoring	Total (GPU hours)	AUC(%)
LAVAD	-	5.1h	20h	$7.7h \times 2$	$7.7h \times 2$	55.9	80.28
VADTree-Coarse	0.3h	0.2h	$5.2h \times 2$	-	$2.8h \times 2$	16.5	82.81
VADTree-Fine	0.3h	0.4h	$14.8h \times 2$	-	$7.9h \times 2$	46.1	83.05
VADTree	0.3h	0.6h	$20.0h \times 2$	-	$10.7h \times 2$	62.3	84.74
VADTree-Coarse	0.3h	0.2h	$5.2h \times 2$	-	0.6h $\times$ 2 (no Think)	12.1	82.83
VADTree-Fine	0.3h	0.4h	$14.8h \times 2$	-	1.2h $\times$ 2 (no Think)	32.7	82.72
VADTree	0.3h	0.6h	$20.0h \times 2$	-	1.8h $\times$ 2 (no Think)	44.5	84.65
VADTree-Coarse	0.3h	0.2h	$5.2h \times 2$	-	0.1h $\times$ 2 (t5gemma-9B-2B)	11.1	82.21
VADTree-Fine	0.3h	0.4h	$14.8h \times 2$	-	0.2h $\times$ 2 (t5gemma-9B-2B)	30.0	82.19
VADTree	0.3h	0.6h	$20.0h \times 2$	-	0.3h $\times$ 2 (t5gemma-9B-2B)	41.5	84.00

Table 16 · 모델별 구성요소 GPU 시간 · 클릭하여 원문 확대

기본 Think

VADTree 62.3 GPU·h
LAVAD 55.9 GPU·h

no-Think

44.5 GPU·h
AUC 84.65

비용의 주된 위치

기본 VLM caption 40.0
LLM scoring 21.4 GPU·h

UCF 정성 사례




Fig. 3 위쪽 · UCF 절도와 정상 매장 · 클릭하여 원문 확대

절도 · 왼쪽

빨간 GT 구간과 파란 최종 점수의 상승이 대체로 대응한다. 시작·끝은 정확히 일치하지 않는다.

정상 매장 · 오른쪽

물건을 들고 움직이는 행동을 일상 업무로 설명하고 점수를 낮게 유지한다.

청록=coarse, 분홍=fine, 빨간 영역=GT, 파란 선=최종 이상 점수. 설명 문장은 모델 생성 텍스트.

XD 정성 사례




Fig. 3 아래쪽 · XD 폭행과 시위 · 인터뷰 전환 · 클릭하여 원문 확대

행동 변화 · 왼쪽

제압·저항 행동이 보이는 구간에서 짧은 노드와 점수 상승이 대응한다.

장면 전환 · 오른쪽

충돌 장면과 인터뷰 구간의 설명·점수가 달라 긴 맥락과 짧은 단서가 갈린다.

정성 사례는 작동 방식을 보여준다. 평균 성능과 설명 충실도는 별도 평가가 필요하다.

한계와 후속 질문

원문에 명시된 한계

VLM이 작은 이상 단서를 시각 입력에서 놓치면 뒤의 언어 추론·점수 보정으로 복구하기 어렵다.

온라인 적용

전체 트리와 다른 노드의 점수를 참조한다. 미래 프레임 없이 언제 점수를 확정할지는 별도 설계다.

설명 충실도

사전 지식이 유용해도 설명을 한쪽으로 유도할 수 있다. 문장과 실제 영상의 일치를 따로 봐야 한다.

성능·비용의 범위

AUC, AP, 구간 수, GPU 시간은 서로 다른 결과다. 같은 단위와 입력 조건에서 비교해야 한다.

첫 항목은 저자가 명시한 한계. 나머지는 방법과 실험 범위에서 도출한 발표자의 후속 검증 질문.

결론

문제

고정 길이 창과 다양한 사건 길이의
불일치

방법

일반 경계 트리 → 구간 판단 → 이웃
보정 → 부모·자식 융합

근거의 범위

AUC와 샘플 수의 개선
AP·총비용·설명 충실도는 별도

사건을 한 길이로 볼 것인가, 여러 시간 문맥에서 함께 볼 것인가?